

Klasifikacija Uzoraka Genske Ekspresije

Projekat na kursu Istraživanje podataka 2

1. Uvod i opis zadatka

Genska ekspresija predstavlja jedan od najinformativnijih izvora bioloških podataka u savremenoj biomedicinskoj nauci. Mikroarray tehnologija omogućava istovremeno merenje nivoa ekspresije desetine hiljada gena u jednom uzorku tkiva, otvarajući mogućnost da se različite vrste oboljenja identifikuju na molekularnom nivou — pre nego što klinički simptomi postanu vidljivi.

Cilj ovog istraživanja je razvoj modela mašinskog učenja za binarnu klasifikaciju uzoraka genske ekspresije preuzetih iz repozitorijuma OpenML (ID: 1161). Zadatak se svodi na razlikovanje uzoraka koji potiču iz tkiva debelog creva (*Colon*) od svih ostalih uzoraka (*Other*). Poseban izazov predstavlja *prokletstvo dimenzionalnosti*: skup podataka sadrži više od 10.000 gena kao atributa, što većinu algoritama mašinskog učenja čini računski zahtevnim i sklonima preprilagđavanju.

Problem je dodatno otezan sa *nebalansiranjem klasa*: klasa *Colon* znatno je manje zastupljena od klase *Other*, što navodi naivne algoritme da većinski klasu uvek predviđaju i na taj način postizati visoku ukupnu tačnost bez ikakve stvarne prediktivne vrednosti. Iz tog razloga, primarna metrika uspeha nije ukupna tačnost (*accuracy*), već **F1 skor za klasu *Colon***, koji ujedno uzima u obzir i preciznost i odziv za klasu od interesa.

Rad obuhvata celokupan pipeline: od preprocesiranja i redukcije dimenzionalnosti, kroz trening i podešavanje parametara šest različitih algoritama klasifikacije, do sistematske evaluacije i interpretacije rezultata.

2. Opis podataka

Podaci korišćeni u ovom radu potiču iz OpenML repozitorijuma i dostupni su pod ID: 1161. Reč je o skupu podataka genske ekspresije koji obuhvata uzorke različitih vrsta tumora, prikupljene u cilju izgradnje dijagnostičkih modela baziranih na molekularnim profilima.

Broj instanci: 1.545 uzoraka tkiva.

Broj atributa: 10.936 gena merenih mikroarray tehnologijom.

Ciljna promenljiva: Klasa uzorka — *Colon* (uzorak debelog creva) ili *Other* (svi ostali tipovi tkiva).

Distribucija klasa odražava jaku neravnotežu karakterističnu za realne biomedicinske skupove podataka: klasa *Colon* zastupljena je sa svega oko 4% svih instanci, dok preostalih 96% čine uzorci klase *Other*. Ova neravnoteža direktno ugrožava performanse standardnih algoritama — model koji uvek predviđa klasu *Other* postigao bi tačnost od oko 96% uz potpuno odsustvo dijagnostičke vrednosti.

3. Metodologija i obrada podataka

3.1. Učitavanje podataka

Skup podataka preuzet je direktno iz OpenML repozitorijuma korišćenjem biblioteke `sklearn.datasets.fetch_openml` sa ID: 1161. Nakon učitavanja, izvršena je analiza podataka: provera dimenzija, tipova atributa, distribucije ciljnih klasa i prisustva nedostajućih vrednosti.

3.2. Obrada nedostajućih vrednosti i autlajera

Nedostajuće vrednosti nisu prisutne u ovom skupu podataka. Analiza autlajera izvršena je vizuelizacijom box-plot dijagrama za reprezentativni uzorak atributa, pri čemu je zaključeno da su ekstremne vrednosti biološki prihvatljive i ne treba ih uklanjati.

3.3. Standardizacija atributa

Na svim atributima primenjen je **StandardScaler**, koji svaki atribut transformiše na nultu srednju vrednost i standardnu devijaciju jedan. Ova transformacija ključna je za algoritme kao što su SVM i k-NN, gde udaljenosti ili optimizacioni kriterijumi direktno zavise od apsolutnih vrednosti atributa. StandardScaler je fitovan isključivo na trening skupu kako bi se izbeglo curenje informacija o test skupu.

3.4. Rešavanje problema nebalansiranosti — BorderlineSMOTE

Kako bi se ovaj problem prevazišao, primenjena je tehnika **BorderlineSMOTE** (*Borderline Synthetic Minority Over-sampling Technique*). Za razliku od standardnog SMOTE-a koji generiše sintetske primere ravnomerno duž celog regiona manjinske klase, BorderlineSMOTE fokusira sintezu novih instanci na *granučne* primere — tačke manjinske klase koje su okružene primerima većinske klase i samim tim predstavljaju najosetljivije zone gde modeli najčešće greše.

Ovaj pristup je teorijski superioran u odnosu na uniformno generisanje, jer usmerava kapacitet modela tačno tamo gde je to najvažnije: na učenje granice odluke u blizini klase *Colon*. Korišćen je parametar `k_neighbors=3` zbog male veličine manjinske klase. Važno je napomenuti da je BorderlineSMOTE primenjen isključivo na trening skupu, nakon podele podataka, kako bi se sprečilo curenje sintetskih podataka u evaluaciju.

3.5. Redukcija dimenzionalnosti — PCA

Sa 10.936 gena, direktna primena većine algoritama klasifikacije nije računski efikasna. Stoga je primenjena **PCA** (*Principal Component Analysis*) redukcija dimenzionalnosti, koja transformiše originalni prostor gena u manji prostor glavnih komponenti koji čuva najvažniju varijansu podataka.

Korišćene su dve varijante PCA:

- **PCA-70**: zadržava komponente koje objašnjavaju 70% ukupne varijanse.
- **PCA-80**: zadržava komponente koje objašnjavaju 80% ukupne varijanse.

Za svaku varijantu generisani su skupovi podataka bez i sa primenjenim BorderlineSMOTE-om, što daje četiri PCA skupa za trening. PCA je fittovan isključivo na trening skupu,

dok se test skup transformiše bez ponovnog fitovanja.

Za potrebe vizuelizacije, primenjena je PCA projekcija na dva i tri glavna faktora, pri čemu je učinjena opservacija o stepenu linearne separabilnosti klasa u redukovanoim prostoru.

3.6. Selekcija atributa — SelectKBest

Alternativni pristup redukciji dimenzionalnosti je **selekcija atributa**, umesto transformacije prostora, odabira se podskup najrelevantnijih originalnih gena. Primenjena je metoda **SelectKBest** sa ANOVA F-testom (`f_classif`), koja meri statističku zavisnost između svakog gena i ciljne klase i rangira gene po F-skoru.

Eksperimentisano je sa šest različitih veličina podskupa: **top-20**, **top-30**, **top-40**, **top-50**, **top-100** i **top-200** gena. Za svaki podskup primenjen je BorderlineSMOTE i generisan zasebni fajl podataka. Ovaj dizajn omogućava analizu uticaja broja selektovanih gena na performanse svakog algoritma.

Selekcija atributa donosi dvostruku korist: smanjuje rizik od preprilagođavanja eliminacijom šumnih i redundantnih gena i povećava interpretabilnost modela jer su konačni atributi biološki značajni originalni geni, a ne apstraktne linearne kombinacije.

3.7. Vizualizacija — t-SNE i korelaciona analiza

U cilju intuitivnog razumevanja strukture podataka, primenjena su dva vida vizuelizacije:

t-SNE (*t-Distributed Stochastic Neighbor Embedding*) je nelinearna metoda koja projektuje visokodimenzionalne podatke u dvodimenzionalni prostor uz očuvanje lokalne strukture okolina. Za razliku od PCA, t-SNE može da razotkrije nelinearne klastere koji su nevidljivi u linearnoj projekciji, što ga čini važnim dijagnostičkim alatom za razumevanje separabilnosti klasa.

Korelaciona matrica top selektovanih gena vizuelizovana je kao heatmap, otkrivajući grupe visoko korelisanih gena. Ova analiza je informativna za razumevanje redundantnosti atributa i pruža uvid u to da li selekovani geni nose nezavisne biološke informacije ili su međusobno redundantni.

4. Korišćeni algoritmi

4.1. Logistička regresija

Logistička regresija služi kao osnovni model i standard za poređenje. Uprkos svojoj relativnoj jednostavnosti, logistička regresija ima nekoliko važnih prednosti: interpretabilnost koeficijenata i robustnost na manje skupove podataka. Posebno je prikladna za PCA-transformisane skupove podataka gde su atributi već dekorelisani, što eliminiuje problem multikolinearnosti koji bi inače narušio interpretabilnost koeficijenata.

Eksperimentisano je sa L1 i L2 regularizacijom (parametar `penalty`), uz vrednosti regularizacionog parametra $C \in \{0.01, 0.1, 1, 10\}$, korišćenjem `liblinear` i `saga` resavača koji podržava oba vida regularizacije u visokim prostorima.

4.2. Naivni Bajes

Gausov naivni Bajes je probabilistički klasifikator koji pretpostavlja uslovnu nezavisnost atributa date klase i modeluje svaki atribut Gausovom distribucijom.

Jedini hiperparametar je `var_smoothing` $\in \{10^{-12}, 10^{-11}, \dots, 10^{-7}\}$, koji stabilizuje procenu varijanse gena sa malim varijabilitetom i sprečava numeričke probleme pri deljenju sa veoma malim vrednostima varijanse.

Naivni Bajes je testiran na širem spektru skupova podataka nego ostali algoritmi, uključujući sirove (neskalirane) i skalirane podatke bez redukcije, što pruža uvid u njegovu robustnost na različite oblike preprocesiranja.

4.3. XGBoost

XGBoost (*eXtreme Gradient Boosting*) je ansambl metoda bazirana na sekvencijalnom nadograđivanju stabala odluke, pri čemu svako naredno stablo koriguje greške prethodnog.

Eksperimentisano je sa tri ključna hiperparametara: brojem stabala `n_estimators` $\in \{50, 100, 200\}$, maksimalnom dubinom `max_depth` $\in \{3, 5, 7\}$ i stopom učenja `learning_rate` $\in \{0.05, 0.1, 0.2\}$. Plitka stabla (`max_depth=3`) favorizuju generalizaciju i smanjuju rizik od preprilagođavanja, dok dublja stabla omogućavaju modelovanje kompleksnijih interakcija među genima.

Budući da XGBoost zahteva numeričke oznake klase, primenjena je preslikavanje *Other* $\rightarrow 0$, *Colon* $\rightarrow 1$.

4.4. Random Forest

Random Forest je ansambl metoda koja kombinuje veliki broj stabala odluke, pri čemu svako stablo trenira na nasumičnom poduzorku podataka i nasumičnom podskupu atributa. Ovaj pristup drastično smanjuje varijansu modela i rizik od preprilagođavanja, a inherentno pruža procenu važnosti atributa kroz *Gini impurity* redukciju.

Sproveden po sledećim parametrima: broj stabala `n_estimators` $\in \{50, 100, 200\}$, maksimalna dubina `max_depth` $\in \{5, 10, 15, \text{None}\}$ i minimalni broj uzoraka za podelu `min_samples_split` $\in \{2, 5, 10\}$.

Pored predikcije, Random Forest pruža rang važnosti gena koji komplementira nalaze SelectKBest analize i pruža uvid u to koji geni najviše prinosе znacaju.

4.5. Linearni SVM (LinearSVC)

Linearni SVM (*Support Vector Machine*) pokušava da pronađe optimalnu hiperravan koja maksimizuje marginu između dve klase. Za visokodimenzionalne skupove podataka kao što su genska ekspresija, linearno jezgro je često izuzetno efikasno jer su klase linearno separabilne u originalnom prostoru visoke dimenzije.

Korišćena je implementacija `LinearSVC` koja je računski znatno efikasnija od `SVC(kernel='linear')` i podržava oba tipa gubitka: `hinge` i `squared_hinge`. Eksperimentisano je sa regularizacionim parametrom `C` $\in \{0.001, 0.01, 0.1, 1, 10, 100\}$.

4.6. k-Najbližih suseda (k-NN)

k-NN je algoritam koji klasifikuje novu instancu na osnovu klase njenih k-najbližih suseda u prostoru obeležja. Algoritam ne gradi eksplicitan model, već čuva sve trening primere u memoriji.

Medjutim, k-NN je posebno osetljiv na **prokletstvo dimenzionalnosti**: u prostorima sa više od nekoliko stotina dimenzija, pojam “blizine” gubi smisao jer su sve tačke približno jednako udaljene, što čini osnovu algoritma beskorisnom. Iz tog razloga, k-NN je treniran isključivo na skupovima podataka sa najmanji brojem atributa: **top-20**, **top-30**, **top-40** i **top-50** gena selektovanih ANOVA F-testom. Na ovim skupovima, gde je dimenzionalnost redučovana na svega 20–50 najinformativnijih gena, pojam udaljenosti je ponovo smislen.

Eksperimentisano je sa brojem suseda $k \in \{3, 5, 7, 9, 11, 15, 21\}$, težinskim shemama **uniform** i **distance**, kao i merama udaljenosti Euklidskom i Menhetn metrikom.

5. Evaluacija — metrike i vizuelizacije

5.1. Metrike evaluacije

Svaki model je evaluiran kroz više metrika kako bi se dobila potpuna slika njegovih performansi.

- **F1 skor**: harmonična sredina preciznosti i odziva.
- **Ukupna tačnost (Accuracy)**: udeo tačnih predikcija u ukupnom broju instanci. Korisna, ali nepotpuna slika za nebalansirane skupove.
- **AUC-ROC**: površina ispod ROC krive. Meri diskriminacionu sposobnost modela nezavisno od konkretnog praga odluke.
- **Average Precision (AP)**: površina ispod Precision-Recall krive.
- **Matrica konfuzije**: prikazuje raspodelu tačno pozitivnih, lažno pozitivnih, tačno negativnih i lažno negativnih predikcija.

5.2. Unakrsna validacija

Kako bi se osigurala robustnost evaluacije i minimizovao uticaj konkretne podele podataka, primenjena je **stratifikovana 5-fold unakrsna validacija**. Stratifikacija osigurava da svaki fold zadrži isti udeo klase *Colon* kao originalni skup, što je kritično za nebalansirane skupove gde slučajna podela može da dovede do foldova bez ijednog pozitivnog primera.

Unakrsna validacija primenjena je za svaku kombinaciju algoritma, skupa podataka i vrednosti hiperparametara, generišući distribuciju F1 i tačnosti po foldovima. Rezultati su vizuelizovani box-plot dijagramima koji prikazuju stabilnost performansi i standardnu devijaciju po foldovima.

5.3. ROC krive i AUC

ROC (*Receiver Operating Characteristic*) kriva vizuelizuje trade-off između stope tačno pozitivnih (TPR) i stope lažno pozitivnih (FPR) pri različitim pragovima klasifikacije. Površina ispod krive (AUC) služi kao skalarna mera ukupne diskriminacione sposobnosti modela.

5.5. Matrica konfuzije

Za model sa najboljim ukupnim F1 skorom generisana je matrica konfuzije koja jasno prikazuje raspodelu svih predikcija: tačno detektovani uzorci klase *Colon* (TP), propušteni uzorci klase *Colon* (FN), lažni uzorci klase *Other* (FP) i tačno odbijeni uzorci klase *Other* (TN).

U biomedicinskom kontekstu, greške Tipa II (FN — propušteni uzorci) nose veće kliničke posledice od grešaka Tipa I (FP — lažna uzbuna).

5.6. Važnost atributa — Random Forest

Random Forest kao ansambl stabala ima sposobnost merenja važnosti atributa kroz Gini nečistoću. Top geni rangirani su po prosečnoj važnosti kroz sva stabla u ansamblu i prikazani horizontalnim bar grafikom. Ovaj grafik dopunjuje nalaze SelectKBest analize i pruža biološki interpretabilan uvid u to koji geni najviše doprinose razlikovanju uzoraka debelog creva od ostalih tipova tkiva.

6. Analiza rezultata

Svaki od šest algoritama treniran je i evaluiran na više varijanti podataka: PCA-redukovani skupovi (sa 70% i 80% zadržane varijanse, sa i bez BorderlineSMOTE-a), skupovi selektovanih gena (top-20 do top-200), a naivni Bajes dodatno i na sirovim i skaliranim podacima. Ovakav dizajn eksperimenta otkriva uticaj različitih strategija preprocesiranja na performanse svakog algoritma.

6.1. Uticaj redukcije dimenzionalnosti

Ključno pitanje ovog istraživanja je da li redukcija dimenzionalnosti poboljšava klasifikaciju. PCA-redukovani skupovi smanjuju broj atributa sa 10.936 na svega nekoliko stotina komponenti, ali istovremeno gube interpretabilnost originalnih gena. Selekcija gena (SelectKBest) održava interpretabilnost jer su odabrani atributi biološki značajni originalni geni, ali ostavlja šum koji PCA eliminiše rotacijom.

6.2. Prokletstvo dimenzionalnosti i k-NN

Ograničavanje k-NN algoritma na skupove sa top-20 do top-50 gena direktna je posledica prokletstva dimenzionalnosti. U prostoru sa 10.936 dimenzija, Euklidska udaljenost postaje besmislena jer se razlike među tačkama ne razlikuju puno. Redukovanjem na 20-50 najinformativnijih gena, algoritam dobija smislen pojam susednosti i može efikasno da uči lokalne granice odluke.

6.3. Gap između F1 i tačnosti — analiza nebalansiranosti

Razlika između F1 skora i ukupne tačnosti (*gap*) služi kao kvantitativna mera nebalansiranosti u kontekstu konkretnog modela. Modeli sa velikim gap-om pokazuju da je većina tačnih predikcija posledica ispravnog prepoznavanja većinske klase, dok se manjinska klasa često greši. Modeli sa malim gap-om efektivno su naučili obe klase.

Scatter dijagram F1 vs tačnost za sve kombinacije algoritama i skupova podataka vizualizuje ovu distribuciju i omogućava identifikaciju algoritama koji konzistentno dobro balansiraju

obe metrike.

7. Zaključak

7.1. Selekcija gena kao ključ uspeha

Rezultati istraživanja potvrđuju centralnu hipotezu rada: visoka dimenzionalnost genska ekspresionih podataka nije prednost, već izazov koji se mora pažljivo adresirati. Redukcijom na manji broj visoko informativnih gena – bilo PCA transformacijom ili ANOVA-baziranom selekcijom – algoritmi dobijaju čišći signal bez šuma koji nastaje iz desetina hiljada gena niske prediktivne vrednosti.

Ova opservacija ima i biološku značenje: ekspresija samo nekoliko gena može biti dovoljan biološki marker za razlikovanje tkiva debelog creva od ostalih tipova.

7.2. Balansiranje podataka kao neophodan korak

Istraživanje je potvrdilo da je primena tehnike BorderlineSMOTE apsolutno nezaobilazna u radu sa nebalansiranim biomedicinskim podacima. Bez veštačkog generisanja primera manjinske klase, algoritmi bi, usled optimizacije ukupne greške, težili da svaki uzorak klasifikuju kao *Other* i pri tom postigli visoku tačnost bez ikakve stvarne dijagnostičke vrednosti. Pravilno balansiranje omogućava modelu da nauči suptilne, ali kritične obrasce genske ekspresije koji karakterišu klasu *Colon*.

Prednost BorderlineSMOTE-a nad standardnim SMOTE-om leži u fokusiranju sinteze novih primera tačno na granicu odluke — upravo tamo gde su lažno negativne predikcije najverovatnije. Ovo je posebno važno u biomedicinskom kontekstu gde propušteni pozitivni slučaj (*Colon* klasifikovan kao *Other*) može imati ozbiljne kliničke posledice.

7.3. Prokletstvo dimenzionalnosti i izbor algoritma

Jedan od najvažnijih metodoloških zaključaka je da izbor algoritma mora biti usklađen sa dimenzionalnošću podataka. Algoritmi bazirani na udaljenosti poput k-NN-a zahtevaju agresivnu redukciju dimenzionalnosti i ne treba ih testirati na punom prostoru gena. Nasuprot tome, linearni modeli poput LinearSVC i logističke regresije imaju osobine regularizacije koje im dozvoljavaju rad i u visokim prostorima, ali uz pažljivo podešavanje regularizacionog parametra.